SGLang-Omni｜组件职责与请求数据流

Qwen/Qwen3-TTS-12Hz-1.7B-CustomVoice ・ 默认单 GPU、三个 Stage 同属 pipeline 工作进程(Worker)

01 组件架构：谁负责什么

Stage 是执行组件；Scheduler 在 Stage 内；Coordinator 协调各 Stage。

协调器(Coordinator)

全局请求与状态管理

登记 StageInfo 与通信地址

提交入口任务、接收事件

完成 Future，交还请求结果

不持有各 Stage 的执行实例

流水线执行阶段(Pipeline Stages)

Stage 的职责：收发消息、投递调度、路由结果

预处理 Stage

preprocessing

文本、音色与语言条件

专用调度器(Scheduler)

语音生成 Stage：tts_engine

OmniScheduler

排队、组批、推进 Prefill / Decode

Qwen3TTSModelRunner → 模型计算

音频解码 Stage

vocoder

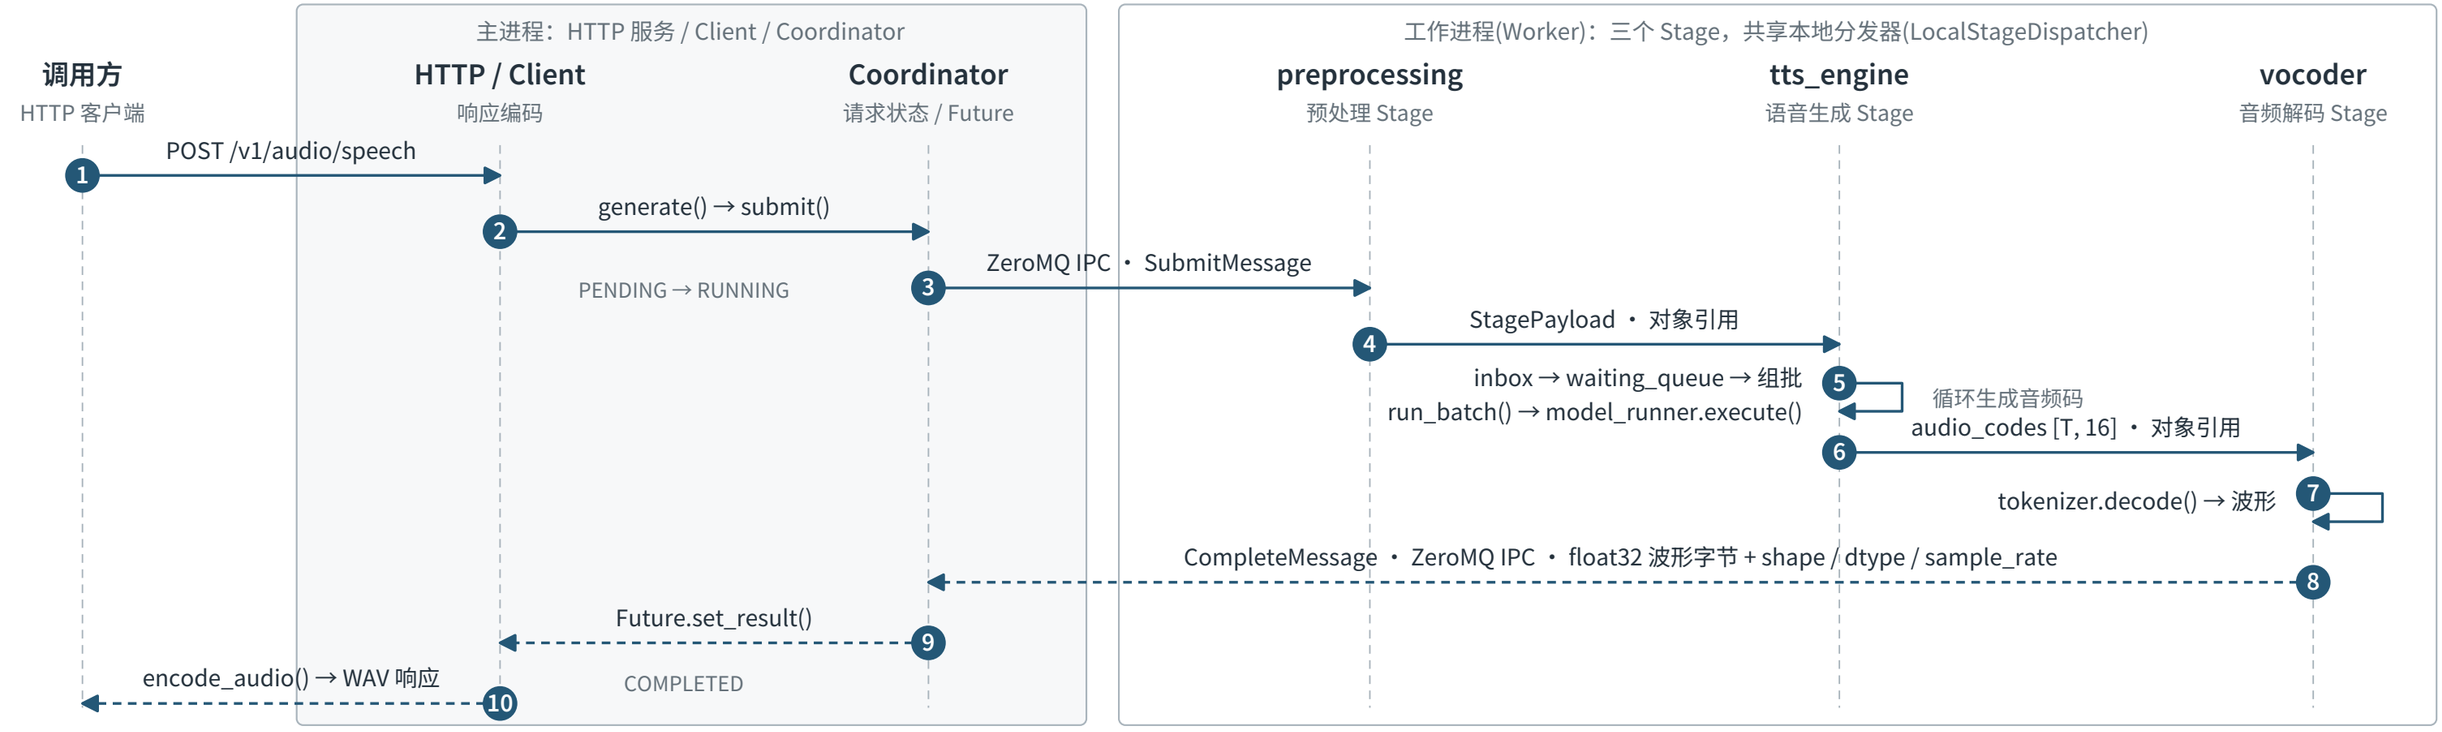
音频码(Audio codes) → 波形

专用调度器(Scheduler)

启动与生命周期 MultiProcessPipelineRunner → StageGroup → 工作进程(Worker) → Stage 框架启动后持续接收请求

02 请求数据流：数据如何走

示例：stream=false，stream_codec_output=false，response_format=wav；仅画成功主链。



通信：Stage ↔ Scheduler 通过 inbox / outbox 线程队列(queue.Queue)；Stage → Stage 通过 LocalStageDispatcher 传对象引用。T 为帧数，16 为码本数。

边界：make_batch_result() 整理 token 结果；vocoder 才执行音频解码。引用传递不等于 GPU 显存(GPU memory) 与 CPU 内存(CPU memory) 之间的 Tensor 拷贝。

调度框架 UML｜继承、持有与依赖

核心关系图：保留模型运行器(ModelRunner)，省略神经网络内部类及非关键成员。箭头方向与实际源码保持一致。

继承　协议实现　组合：管理生命周期　关联：持有对象　依赖：调用 / 创建

A 启动与全局协调

MultiProcessPipelineRunner
_coordinator: Coordinator
groups: list[StageGroup]
start() / stop()

0..*

StageGroup
process_specs
_processes
spawn() / wait_ready()

1..*

StageWorkerProcessSpec
process_name
stage_specs

CoordinatorSessions
sessions

Coordinator
stages: dict[str, StageInfo]
requests / completion_futures
submit() / handle_completion()

stages：0..*

1

CoordinatorControlPlane
stage_sockets
submit_to_stage()
recv_event()

StageInfo
name
control_endpoint

Coordinator 登记 StageInfo；Stage 实例在 Worker 内。
StageGroup 通过进程启动逻辑构造 Stage，属于创建依赖。

B Stage 内部执行与调度

spawn()
子进程构造

Stage
scheduler / control_plane
execute() / route_result()

持有

StageControlPlane
recv_socket / coordinator_socket
recv() / send_complete()

scheduler

«Protocol»
StageScheduler
inbox / outbox: Queue
start() / stop() / abort()

结构实现

OmniScheduler
waiting_queue / model_runner
event_loop_normal()
run_batch()

model_runner

方法复用

ModelRunner
tp_worker
execute()

«SGLang 外部类 · _Upstream»
Scheduler
get_next_batch_to_run()
process_batch_result()

继承

Qwen3TTSModelRunner
before_prefill()
post_process_outputs()

OmniScheduler 复用其方法；
没有继承 Scheduler，
也没有持有其实例。

实线持有关系均以字段为依据。