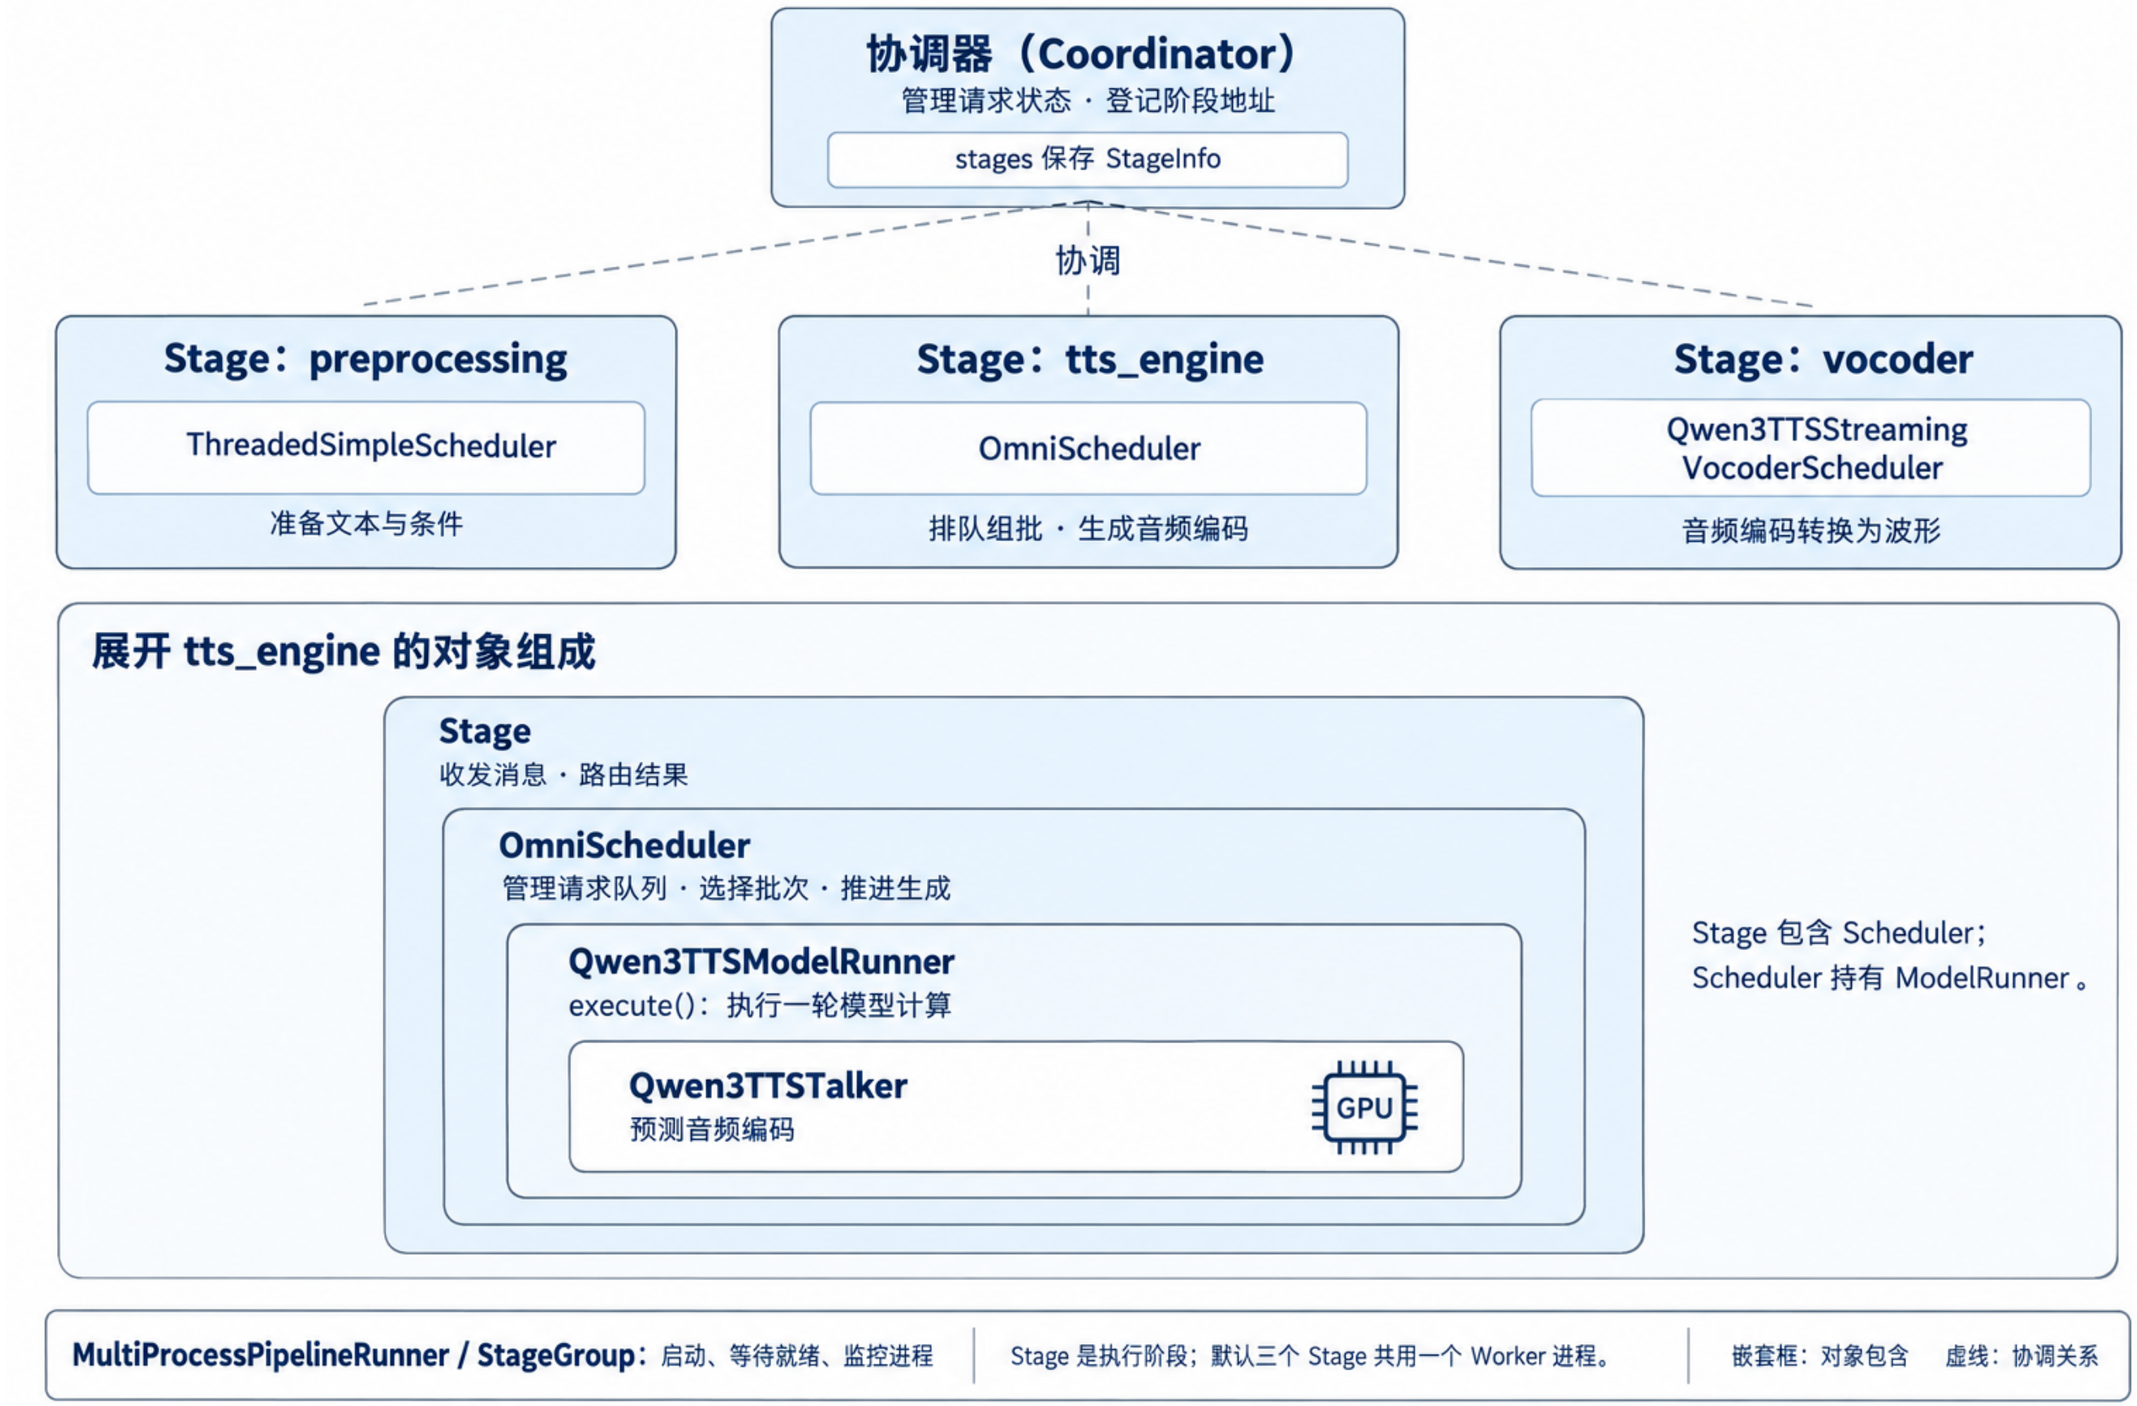
01 组件职责与架构

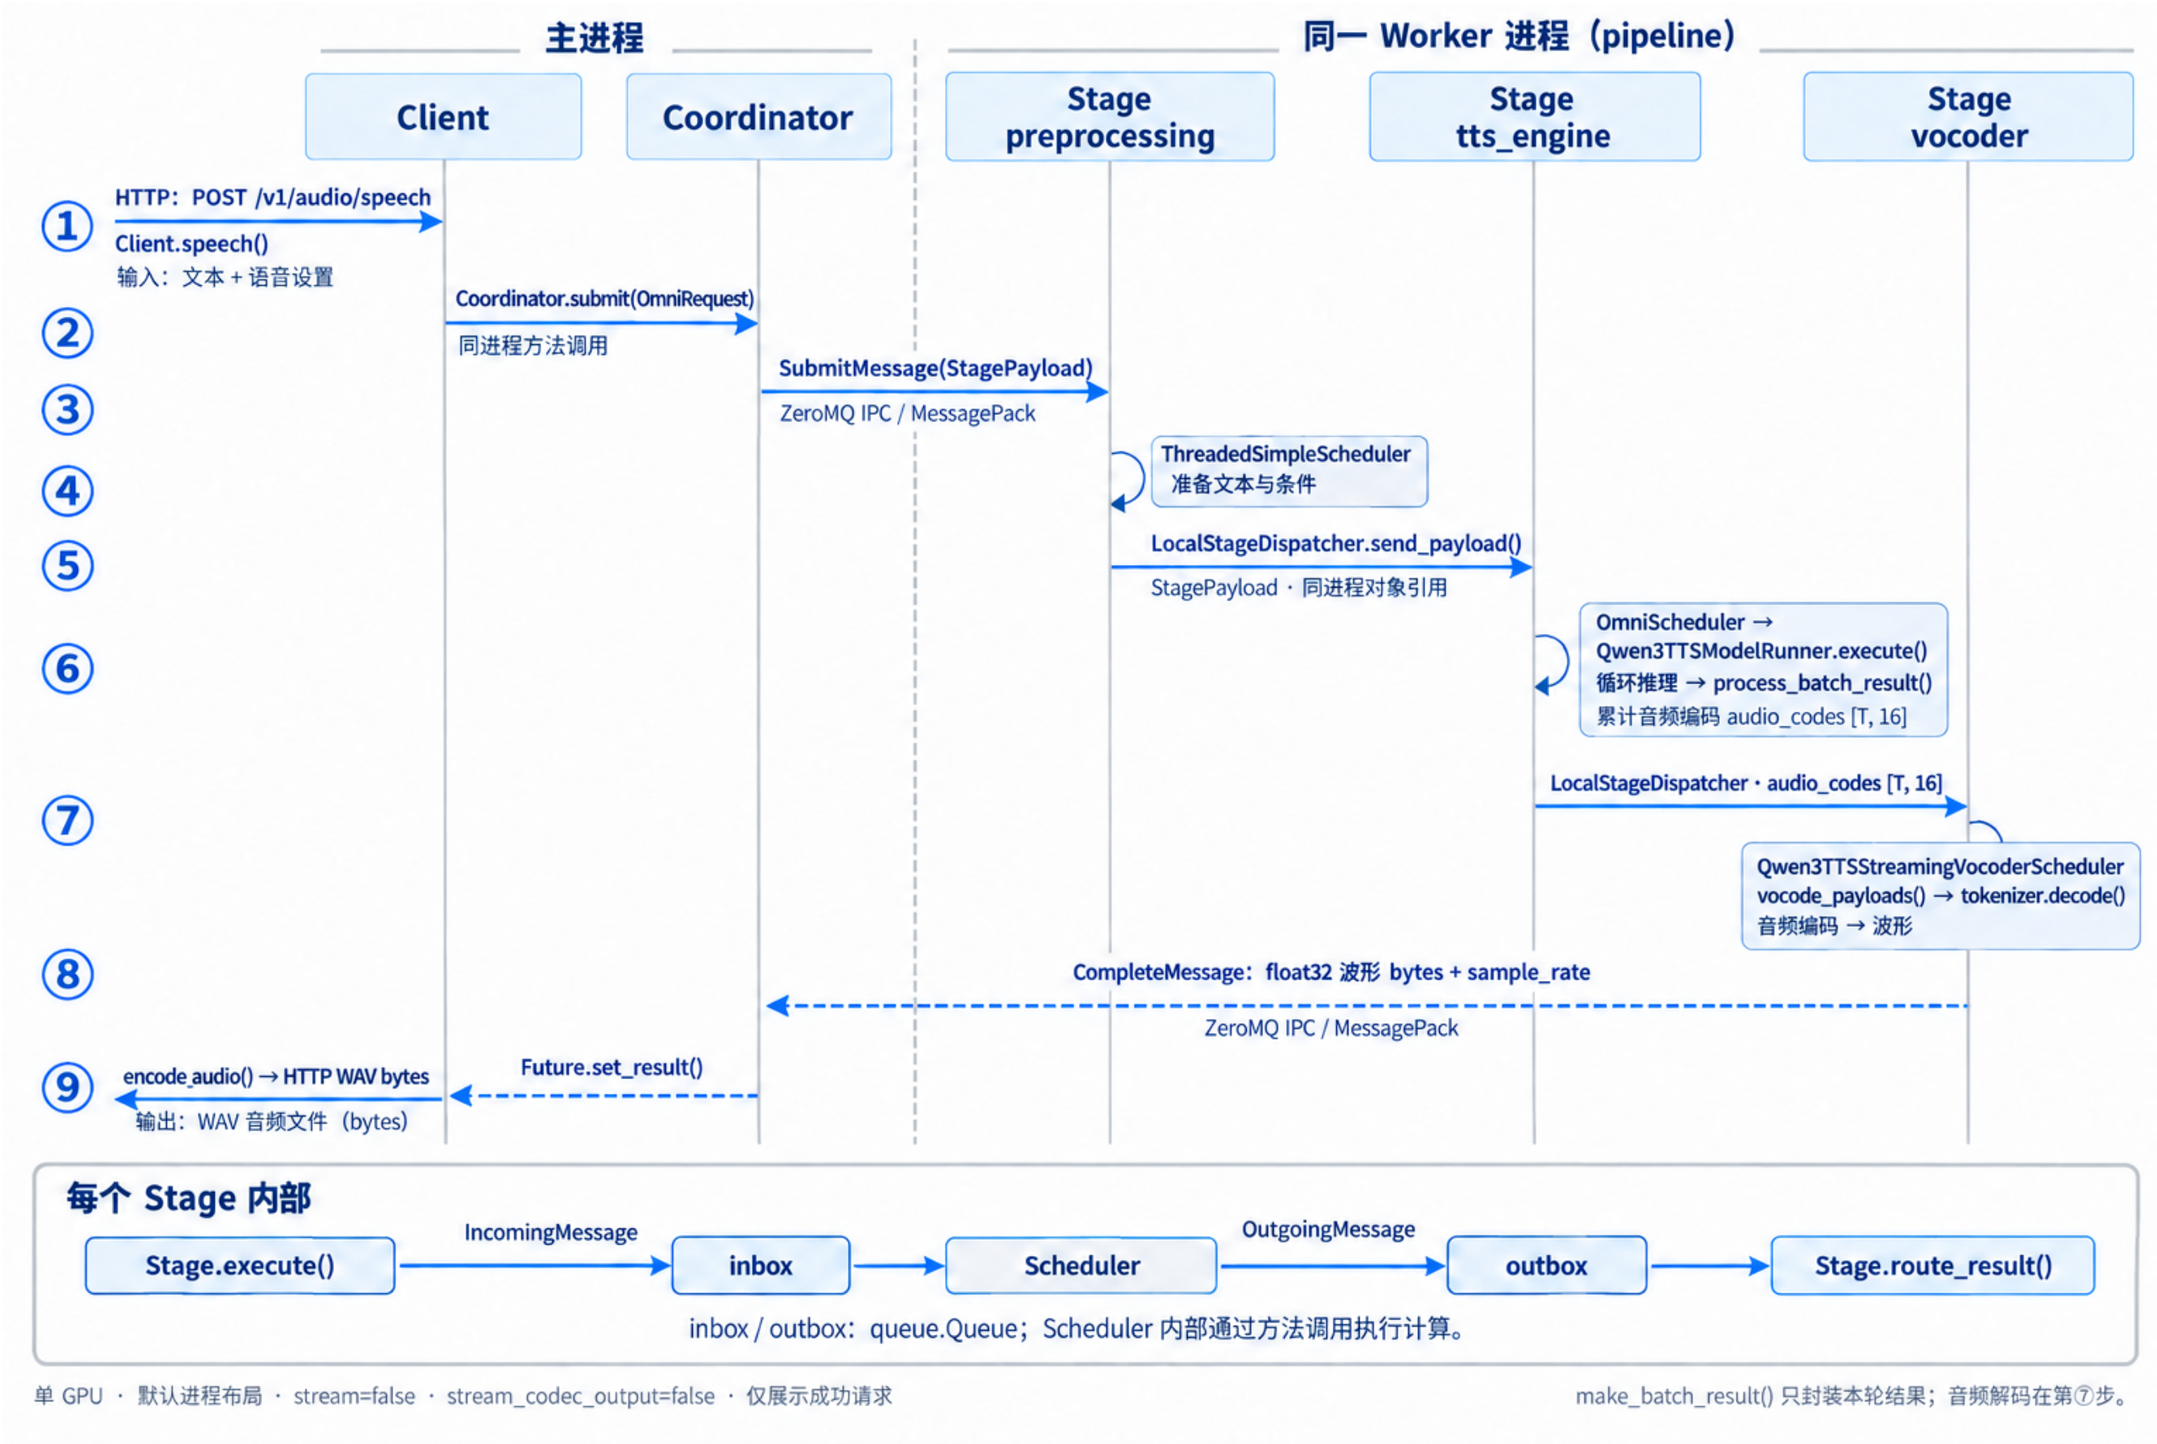
Qwen3-TTS CustomVoice · 对象层级示意省略 ModelWorker / SGLModelRunner 等中间层。



源码：pipeline/{mp_runner,coordinator,stage/runtime}.py · scheduling/omni_scheduler.py · models/qwen3_tts/{config,stages,sglang_model}.py

02 一次请求的数据流

单 GPU · 默认共进程布局 · stream=false · stream_codec_output=false；只展示成功请求的主链路。



单 GPU · 默认进程布局 · stream=false · stream_codec_output=false · 仅展示成功请求

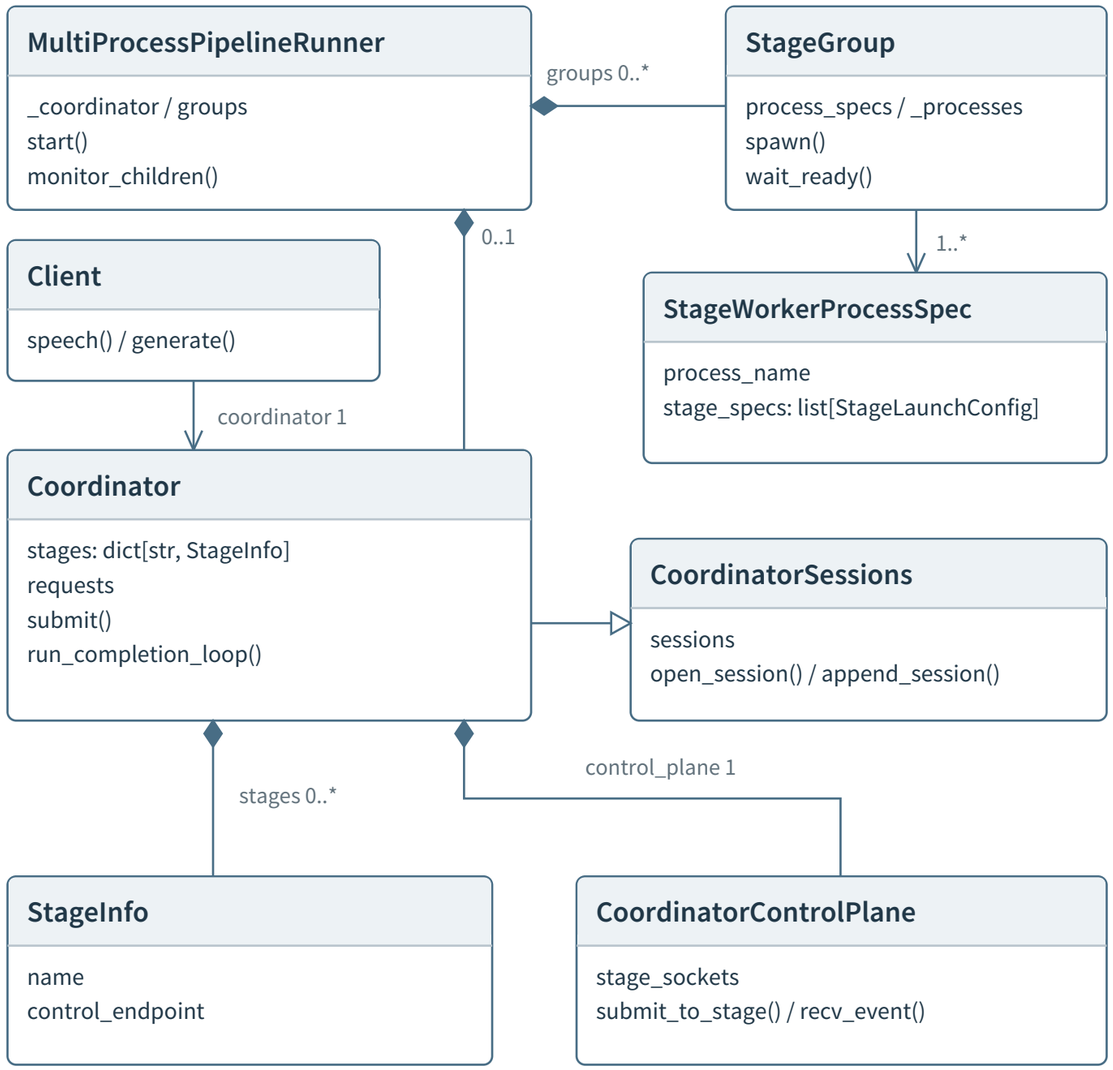
make_batch_result() 只封装本轮结果；音频解码在第⑦步。

源码：client/client.py · pipeline/{control_plane,local_dispatch,stage/runtime}.py · models/qwen3_tts/{request_builders,streaming_vocoder}.py

03 调度框架 UML：继承与对象关系

模型网络之外的 16 个核心类；左右分区表示进程位置，线型表示真实代码关系。

主进程：生命周期与协调



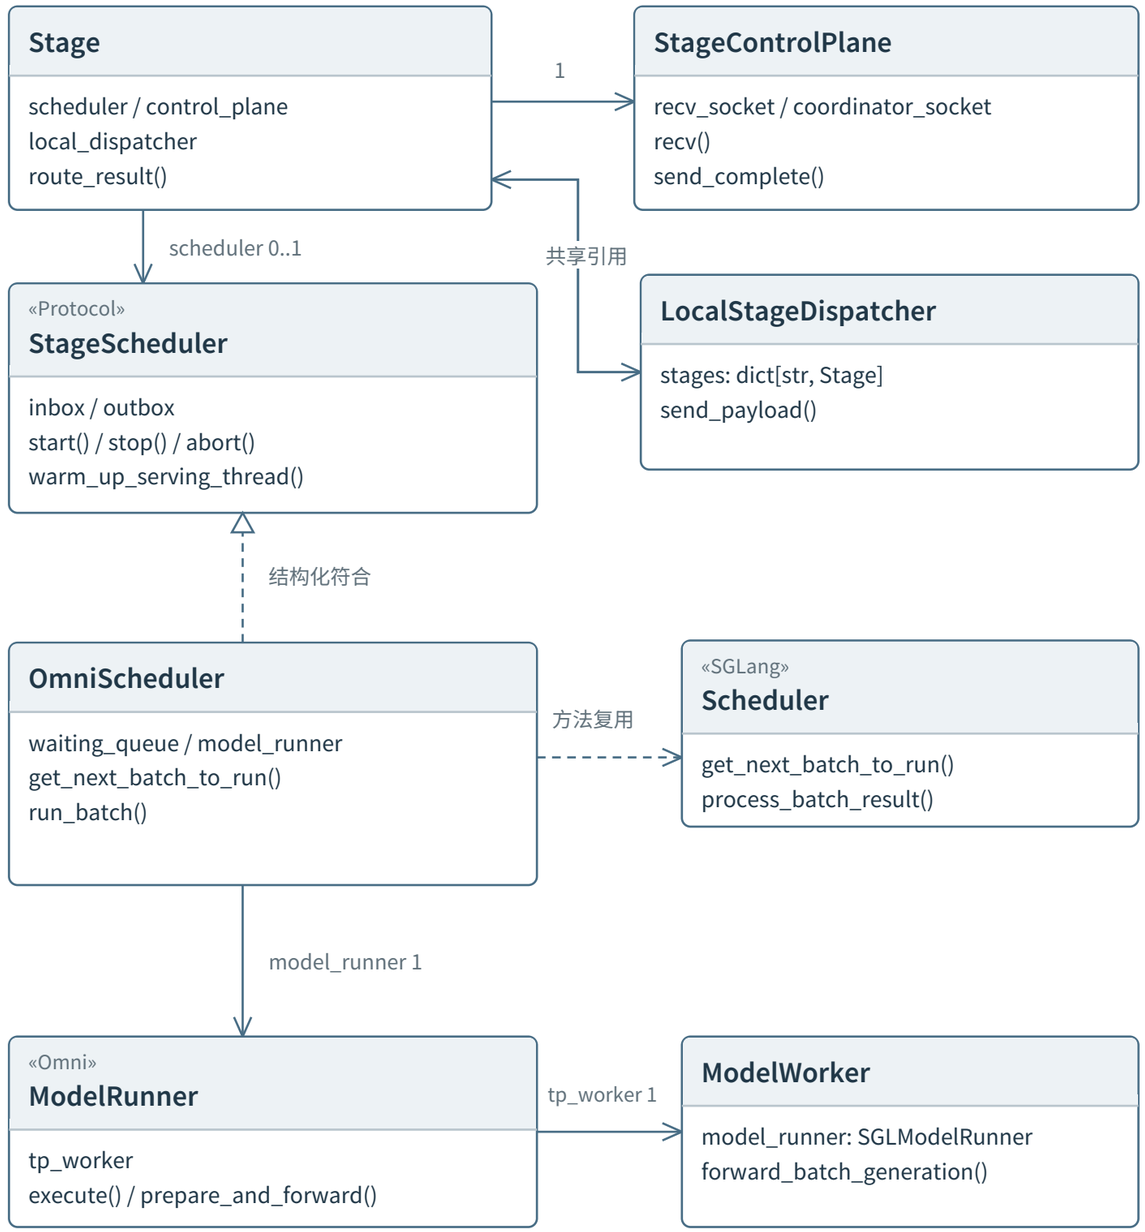
跨进程联系

StageGroup.spawn() → run_process() → 子进程创建 Stage。

主进程持有进程句柄；Coordinator 只登记 StageInfo。

两侧 ControlPlane 通过 ZeroMQ IPC 交换消息。

子进程：阶段、协议与执行



OmniScheduler 与 ModelRunner 的 tp_worker 引用同一个 ModelWorker。

继承(Inheritance)　协议实现(Protocol)　生命周期组合(Composition)　持有引用(Association)　调用依赖(Dependency)

源码：pipeline/{mp_runner,stage_workers,coordinator,control_plane}.py · scheduling/{message,omni_scheduler}.py · model_runner/{base,model_worker}.py